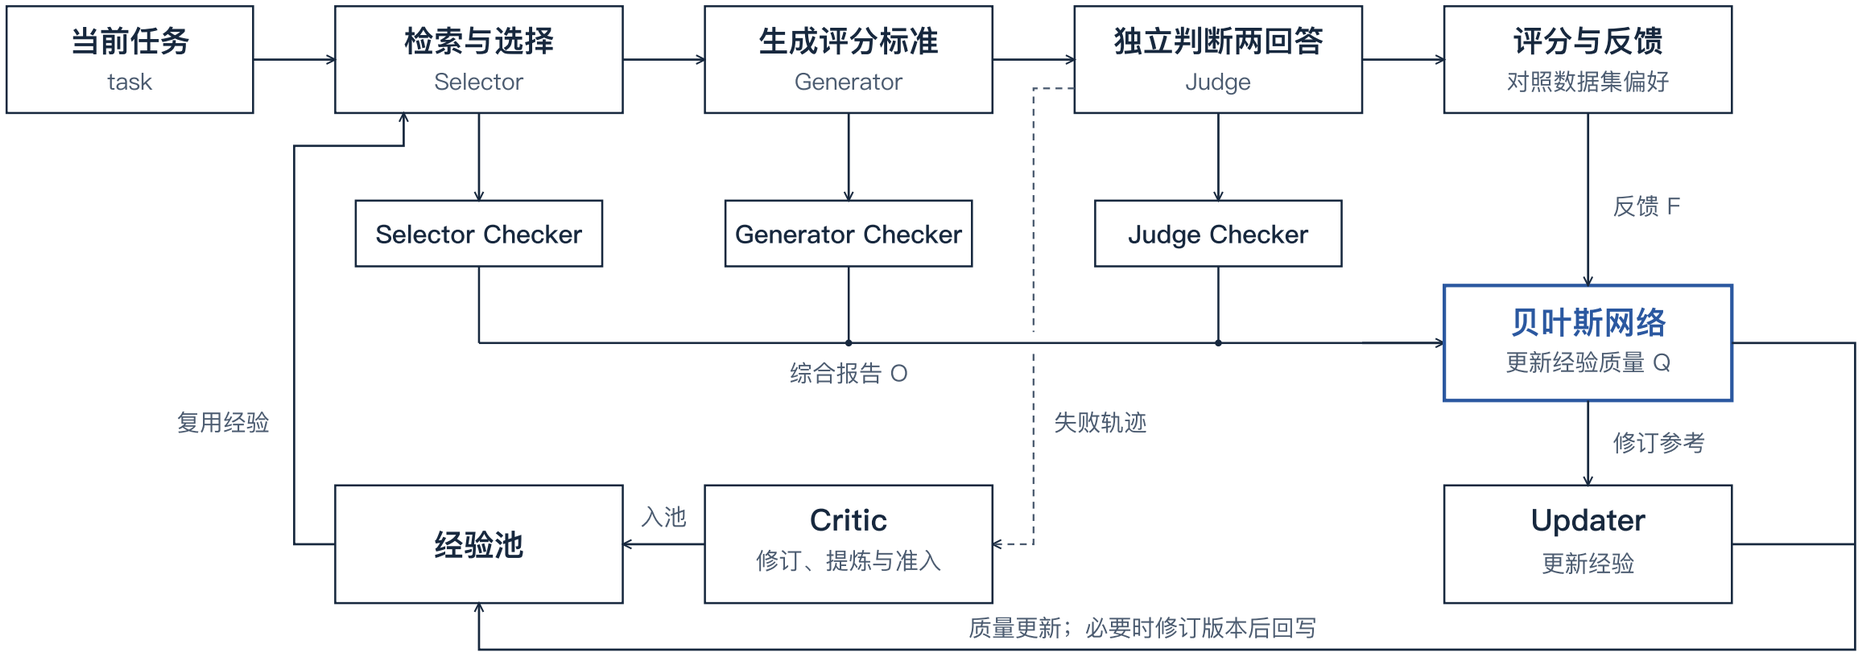
# 各环节都可能出错，经验质量不能只看最终反馈

选择、生成、判断都可能出错；需要区分经验内容与执行问题。

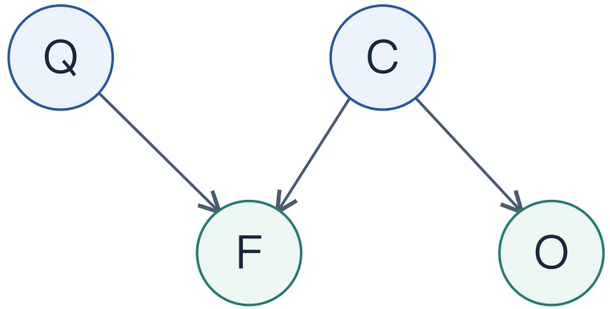



最终反馈混合了经验缺陷与执行错误，不能直接等同于经验质量。

贝叶斯网络结合反馈 F 与核对报告 O 估计经验置信度，并结合具体报告指导修订。

# 用反馈与核对报告，推断经验质量和执行状态

## 1. 简化模型




- **Q** 经验内容质量
- **C** 本次选择、应用与判断的整体执行状态
- **F** 本次应用的正向 / 反向 / 净平局反馈
- **O** 三个Checker的综合核对报告

为简化建模，将三个执行状态合为C，假设F仅依赖Q和C。

### 执行状态与核对报告的汇总

$$C = C_{\text{Selector}} \wedge C_{\text{Generator}} \wedge C_{\text{Judge}}$$

$$O = O_{\text{Selector}} \wedge O_{\text{Generator}} \wedge O_{\text{Judge}}$$

C不可直接观察，O也会误报；P(O | C)描述核对误差。

## 2. 从F、O推断Q、C

$$P\left(Q, C \mid F, O\right) = \frac{P(Q)P(C)P(F \mid Q, C)P(O \mid C)}{Z}$$

先验 × 似然 → 后验

$$P\left(Q \mid F, O\right) = \sum_c P\left(Q, C = c \mid F, O\right)$$

对C求和；Q=0即经验有缺陷的概率

$$P\left(C \mid F, O\right) = \sum_q P\left(Q = q, C \mid F, O\right)$$

对Q求和；C=0即本次执行出错的概率

经验Q的更新：本次后验 → 下次应用的先验

## 3. 参数来源：历史统计

**先验 P(Q)、P(C)** 经验合理率、执行全正确率。

**条件概率 P(F | Q,C)、P(O | C)** 按Q/C统计反馈；按C统计报告误差。

计划由历史应用经多模型标注后统计；当前仍用假设参数。

# 经验改变了评分重点，却不总是朝着正确方向

## 同一批200道题：使用经验与不使用经验的对照

50.5% 无经验　46.0% 有经验　−4.5 个百分点

## 观察到的现象

### 增加额外要求

把经验直接作为本题要求，
超出任务本身要求的内容

### 规则执行过严

把经验中的建议当成必须遵守的规则，
将原本合理的回答判为不合格。

### 评分重点偏移

过多关注经验带来的额外要求，
忽视任务本身的核心要求。

## 可能原因

**经验内容：**规则过强，未明确适用条件与边界。

**选择与应用：**未核实经验是否适用，就将其写入评分标准，容易放大额外要求、忽视核心要求。

## 解决方案

### 明确经验怎么选、怎么用

Selector：什么任务适用，什么情况不选。
Generator：检查什么，不能额外要求什么。

**预期效果：**减少经验误用，让评分更贴合当前任务。

### 先验证修改，再提炼经验

Critic先修改评分标准，确认评分差距改善；
再提炼经验，并核对是否保留修改原意。

**预期效果：**让入池经验有实际改善依据，减少无效或失真的经验。